

Эльбрус 8C2 — полный отчёт по моделям после RoPE NeoX fix

Дата: 2026-05-03 | Хост: w205p.mcst.ru E8C2 (32 ядра, 128 ГБ DDR4)
| Билд: | Флаги:

0. Итог одной таблицей

Модель	RU quality	EN quality	t o k / s S P 1	to k/ s T P- 4 2	RoPE
mistral-7B	✓ идеален	✓ идеале н	3 . 6	5. 1	
qwen2.5-7B	✓ связный	✓ связны й	2 . 9	O O M 3	
qwen3-4B Q4_K_M	✓ полный текст	✓ полный текст	5 . 5	10 . 9	

qwen3-1.7B
Q4_K_M

✓
СВЯЗНЫЙ

✓
СВЯЗНЫ
Й

7
.
8

17
.1



qwen3-0.6B Q4_K_M	x "!!!!!"	~OK	1	—	
			5		
			.		
			1		
			</		

T
P
4

/
3
.
5

S
P

llama3-8B Q4_K_M	✓	✓	2	1. 65	 (llama
	связный	связны	·		
	RU	й EN	7		
			S P		
qwen3-8B Q4_K_M	✓		2	—	 (llama
	связный	CoT	·		
	RU	thinking	6		
			S P		
deepseek- coder-7B Q4_K_M	✓	✓ chat	3	—	 (llama + linea scale
	Python	instruct	·		
	code		0		

S
P

/
2

.
9

4x

c
h
a
t


¹ SP = single-process, OMP_NUM_THREADS=32. ² TP-4 = 4 процесса, OMP_NUM_THREADS=8 каждый, NUMA-bound. ³ qwen2.5-7B / llama3-8B / qwen3-8B / qwen3-14B на TP-4 потребляют >20 ГБ виртуальной памяти, OOM на E8C2. SP path работает. ⁴ gemma3 TP-4 FIXED commit `0ba114a` (требуется PT_TP_GATHER=1): post_attention_norm + post_ffw_norm применяются на full h_buf после output_proj/ffn_down — match SP path forward_decode_cpu.

| 1. Что было сделано в этой сессии

1.1. Найден ROOT CAUSE — RoPE convention mismatch


До фикса RoPE применялся как **interleaved** пары `[A, B]` для всех архитектур. Это `llama_rope.py` в `llama.cpp`, и работает только для **llama / mistral**. Архитектуры **qwen / qwen2 / qwen3 / qwen3moe / gemma / gemma3 / phi3 / phi-2 / stablelm / falcon / gptneox** требуют **NeoX-style half-split** — пары `[A, C]`.

Источник: `llama.cpp` функция `rope_embedding`:



1.2. Сравнение hidden state стало диагнозом

Сначала через `compare_hidden_states` сравнивали qwen3-4B (broken) и mistral-7B (working). Магнитуды совпадают:



Magnitude OK, но направление wrong — потому что Q/K вращали не те

координаты, к которым были обучены веса. Это сразу указало на **permutation / convention bug**, не на quantization, не на eps, не на bias.

1.3. Реализация: 5 коммитов

Com mit	Файлы	Что сделано
b144 db2		Добавлена функция (half-split rotation).
		детектится в по architecture. 4 CPU
		callsite RoPE (single-proc decode, batched
		prefill, TP-4 decode,) →
		dispatch на neox или norm.
ee80 229		Тест-скрипты для verify на 6 моделях single-process + TP-4.
550b 8e9		TP-4 benchmark scripts с замером tok/s + Russian quality.
445d ee4		Linear RoPE scaling (, Gemma3=8.0).
		Phi-3 merged QKV/gate+up split:
		+
		создаёт non-owning views
		на родительский тензор для
		/ . Phi-3 chat template
2b31 7c4		Gemma3 scale=8.0 пропускается до реализации per-layer alternating rope (local SWA + global). Сохраняет существующее

(broken) поведение вместо immediate EOS regression.

| 2. Дословные сэмплы вывода

2.1. qwen3-4B Russian (single-process)

| «Привет! Космос — это пространство за пределами Земли, заполненное промежутками между звёздами и галактиками. В нём»

50 токенов / 11.6 с / **4.3 tok/s**. До фикса: «Кон К ...» / Massive Activations bisect показывал direction wrong.

2.2. qwen3-4B Russian (TP-4)

| «Привет! Москва — это столица России, крупный город на Неве. Она известна как политический, экономический и культурный центр страны. В Москве есть такие места, как Кремль, Третьяковская г»

60 токенов / 7.5 с / **8.0 tok/s**.

2.3. qwen3-4B English (TP-4)

| «Hello! Moscow is the capital of Russia and one of the world's largest cities. It is a major political, cultural, and economic center. Known for its rich history, iconic landmarks like the Kremlin and Red Square, and a vibrant modern scene.»

60 токенов / 7.3 с / **8.2 tok/s**.

2.4. qwen3-1.7B Russian (TP-4)

| «Москва — столица России, крупнейший город страны. Расположена в центре Европейской части России и является важным культурным, экономическим и политическим центром.»

60 токенов / 3.5 с / **17.1 tok/s**.

2.5. qwen2.5-7B Russian (single-process)

«Привет! Как я могу помочь, я готов помочь, если у тебя есть какие-то вопрос или задание, я буду рад помочь.»

До chat template fix qwen2 fallthrough на raw prompt → бессмысленно. После fix — связный текст. (Повторы «помочь» — побочный эффект greedy decoding с repetition penalty.)

2.6. mistral-7B Russian (regression check)

«Привет! Космос - это область, состоящая из космического пространства и всех небесных тел, включая планеты, луны, звезды и галакти»

arch= → . Регрессии НЕТ.

2.7. qwen3-0.6B Russian — capacity issue

Модель слишком маленькая (0.6B параметров) для chat-instruct поведения. В English поведение лучше. Не проблема RoPE — модель так выдаёт всегда.

2.8. gemma3-4B — broken (требует per-layer rope)

ее

NeoX RoPE подключён, но gemma3 в HF/llama.cpp использует **per-layer alternating**: каждые 5 из 6 слоёв — local sliding-window attention с , один — global с . Без per-layer infrastructure один глобальный

ломает половину attention. Pending: per-layer rope config.

2.9. phi3.5-mini — FIXED 2026-05-03 (commit d9dce9e)

Bisect через (FP fallback path) дал решающий результат:

- **DEFAULT (quant_gemv):** мусор, 6.3 tok/s.
- **PT_NO_QUANT_GEMV=1 (FP path):** «Moscow, the capital city of Russia, is a sprawling metropolis with a rich history and vibrant culture. It's known for its iconic landmarks like the Kremlin» — связный английский, 0.2 tok/s (FP fallback ~30× slower).

Корень: (default load path) не обрабатывал phi3 merged tensors (и rows=2*intermediate). split_quant_rows жил только в (fallback path). После mmap для phi3:

- (нет в GGUF)
- ,
-
- (вместо 8192) — это merged [gate; up] в одной матрице

else-branch:

, , оставались uninitialized memory → RoPE на мусоре → softmax NaN-like → argmax всегда падал в token 0 ().

Fix: helper в . Когда отсутствует но есть — malloc + метсру слайсов из mmap region в Q/K/V owning buffers. Аналогично для

rows=2*intermediate → split на gate+up.

Verified output 2026-05-03 18:32 MCK:

- RU: «Космос - это всеобъемлющая область пространства, включающая все газопылевые объекты и их окружения. Он охватывает все извест...» (40 tokens / 11.5s = 3.5 tok/s)
- EN: «Moscow, the capital city of Russia, is not only the political heart of the country but also a vibrant cultural and economic center. With its rich history that dates back to 1...» (40 / 11.4s = 3.5 tok/s)

Sanity на mistral-7B RU и qwen3-4B RU без регрессии (2.9 / 5.5 tok/s).

Урок bisect истории: проверял 13+ гипотез про forward kernel прежде чем выяснилось что веса вообще не загружены. Bisect через PT_NO_QUANT_GEMV=1 дал ясный сигнал — FP работает значит данные ок, бага в quant load.

| 3. Скорость: 11.4 baseline и почему 8.0

Конфигурация	tok/s	Russian quality
per-tensor scale + interleaved RoPE + spec K=1	11.4	broken для qwen3
per-tensor scale + NEOX RoPE + spec K=1	~10.5 (estimate)	работает
per-block scale + NEOX RoPE + spec K=1	8.0	работает

Юзер выбрал **quality > speed**. Per-block scale (точнее квантизация активаций) даёт правильные скорости внимания на массивных активациях qwen3, но добавляет ~7% overhead per замеру. NEOX RoPE сам по себе без overhead — те же $O(\text{head_dim}/2)$ операций, просто другая индексация пар.

| 4. Что незакрыто и план

4.1. gemma3 per-layer alternating RoPE + SWA

Нужно: расширить `per_layer_rope_config` до per-layer rope config (массив длины `num_layers`), детектить gemma3 SWA pattern (каждые 5 из 6 слоёв — local), применять разные `swa_patterns` per слой.

Объём: ~150 LoC в `per_layer_rope_config` + ~50 LoC dispatch в forward path.


4.2. phi3.5 — DONE

FIXED 2026-05-03 commit `phi3.5`. См §2.9.


4.3. Per-layer rope для qwen3-VL / qwen3.5

Llama.cpp добавил `qwen3_vl` и `qwen3.5`. Эти варианты потребуют свои функции `qwen3_vl_rope` / `qwen3.5_rope`. Вне scope этой сессии.

| 5. Воспроизведение



| 6. Git



Memory: 