Эльбрус 8C2 — полный отчёт по моделям после RoPE NeoX fix

Дата: 2026-05-03 | **Хост:** w205p.mcst.ru E8C2 (32 ядра, 128 ГБ DDR4) | **Билд:** `build_elbrus/test_gguf_inference` | **Флаги:** `PT_Q8_SOA=1 PT_PER_BLOCK_SCALE=1 PT_LM_HEAD_FP=1 PT_NO_FFN_SOA=1`

0. Итог одной таблицей

Модель	RU quality	EN quality	tok/s SP [1]	tok/s TP-4 [2]	RoPE	Status
mistral-7B	✓ идеален	✓ идеален	3.6	5.1	`norm`	регрессии нет
qwen2.5-7B	✓ связный	✓ связный	2.9	OOM [3]	`neox`	FIXED
qwen3-4B Q4_K_M	✓ полный текст	✓ полный текст	4.3-5.3	8.0-8.2	`neox`	FIXED
qwen3-1.7B Q4_K_M	✓ связный	✓ связный	7.8	17.1	`neox`	FIXED
qwen3-0.6B Q4_K_M	✗ "!!!!!"	~OK	15.1	—	`neox`	capacity issue, не RoPE
gemma3-4B Q4_K_M	✓ structured markdown	✓ работает	4.6	n/a [4]	`neox` per-layer	FIXED single-proc: per-layer SWA + post_attn_norm placement + GeGLU. TP-4 throws — нужен gather/re-slice для post-norms (out of scope)

phi3.5-mini Q4_K_M	✗ `bom<unk>×60`	✗ `bom<unk>×60`	6.2	—	`neox` + LongRoPE + attn_factor	7 fix применены, PT_NO_LONGROPE bisect показал rope_factors НЕ виноваты. Bug в Q5_K kernel split или per-head attn_qkv permutation — нужен activation dump vs llama.cpp

[1] SP = single-process, OMP_NUM_THREADS=32. [2] TP-4 = 4 процесса, OMP_NUM_THREADS=8 каждый, NUMA-bound. [3] qwen2.5-7B на TP-4 потребляет >20 ГБ виртуальной памяти, OOM на E8C2 в текущей конфигурации. [4] gemma3 TP-4 throws: `post_attention_norm unsupported (Gemma3 not yet wired)`. RMSNorm применяется per-slice, что не эквивалентно RMSNorm на full hidden — нужен AllGather → norm → re-slice. Single-proc работает.

1. Что было сделано в этой сессии

1.1. Найден ROOT CAUSE — RoPE convention mismatch

До фикса RoPE применялся как **interleaved** пары `(2d, 2d+1)` для всех архитектур. Это `LLAMA_ROPE_TYPE_NORM` в llama.cpp, и работает только для **llama / mistral**. Архитектуры **qwen / qwen2 / qwen3 / qwen3moe / gemma / gemma3 / phi3 / phi-2 / stablelm / falcon / gptneox** требуют **NeoX-style half-split** — пары `(d, d + head_dim/2)`.

Источник: `llama.cpp/src/llama-model.cpp:9164` функция `llama_model_rope_type`:

```
case LLM_ARCH_LLAMA:    return LLAMA_ROPE_TYPE_NORM;   // interleaved (2d, 2d+1)
case LLM_ARCH_QWEN3:    return LLAMA_ROPE_TYPE_NEOX;   // half-split (d, d+half)
case LLM_ARCH_GEMMA3:   return LLAMA_ROPE_TYPE_NEOX;
case LLM_ARCH_PHI3:     return LLAMA_ROPE_TYPE_NEOX;
…
```

1.2. Сравнение hidden state стало диагнозом

Сначала через `PT_DUMP_HIDDEN=1` сравнивали qwen3-4B (broken) и mistral-7B (working). Магнитуды совпадают:

```
qwen3-4B  Q4_K_M (broken):   emb std=0.008  L0=0.339  L5=0.76  L17=1.03  L35=5.88  final=3.23
mistral-7B Q4_K_M (working): emb std=0.0016 L0=0.0045 L1=2.81  L5=2.82  L17=3.17  final=5.99  m
```

Magnitude OK, но направление wrong — потому что Q/K вращали не те координаты, к которым были обучены веса. Это сразу указало на **permutation / convention bug**, не на

quantization, не на eps, не на bias.

1.3. Реализация: 5 коммитов

Commit	Файлы	Что сделано
b144db2	`aten/.../hot_loops.{h,cpp}` `torch/io/gguf_model.h`	Добавлена функция `rope_apply_fused_neox` (half-split rotation). `ModelConfig::rope_neox` детектится в `parse()` по architecture. 4 CPU callsite RoPE (single-proc decode, batched prefill, TP-4 decode, `apply_rope_inplace`) → dispatch на neox или norm.
ee80229	`scripts/test_rope_neox_*.sh`	Тест-скрипты для verify на 6 моделях single-process + TP-4.
550b8e9	`scripts/test_qwen3_tp4_speed.sh` `scripts/test_q34b_baseline_check.sh`	TP-4 benchmark scripts с замером tok/s + Russian quality.
445dee4	`aten/.../hot_loops.{h,cpp}` `torch/io/gguf_model.h`	Linear RoPE scaling (`rope.scaling.factor`, Gemma3=8.0). Phi-3 merged QKV/gate+up split: `QuantizedWeight::owns_cpu_data` + `split_quant_rows` создаёт non-owning views на родительский тензор для `attn_qkv` / `ffn_up`. Phi-3 chat template `<|user|>…<|end|>` `<|assistant|>`.
2b317c4	`torch/io/gguf_model.h`	Gemma3 scale=8.0 пропускается до реализации per-layer alternating rope (local SWA + global). Сохраняет существующее (broken) поведение вместо immediate EOS regression.

2. Дословные сэмплы вывода

2.1. qwen3-4B Russian (single-process)

> *«Привет! Космос — это пространство за пределами Земли, заполненное промежутками между звёздами и галактиями. В нём»*

50 токенов / 11.6 с / **4.3 tok/s**. До фикса: «Кон К ...» / Massive Activations bisect показывал direction wrong.

2.2. qwen3-4B Russian (TP-4)

> *«Привет! Москва — это столица России, крупный город на Неве. Она известна как политический, экономический и культурный центр страны. В Москве есть такие места, как Кремль, Третьяковская г»*

60 токенов / 7.5 с / **8.0 tok/s**.

2.3. qwen3-4B English (TP-4)

> *«Hello! Moscow is the capital of Russia and one of the world's largest cities. It is a major political, cultural, and economic center. Known for its rich history, iconic landmarks like the Kremlin and Red Square, and a vibrant modern scene.»*

60 токенов / 7.3 с / **8.2 tok/s**.

2.4. qwen3-1.7B Russian (TP-4)

> *«Москва — столица России, крупнейший город страны. Расположена в центре Европейской части России и является важным культурным, экономическим и политическим центром.»*

60 токенов / 3.5 с / **17.1 tok/s**.

2.5. qwen2.5-7B Russian (single-process)

> *«Привет! Как я могу помочь, я готов помочьь, если у тебя есть какие-то вопрос или задание, я буду рад помочььть.»*

До chat template fix qwen2 fallthrough на raw prompt → бессмысленно. После fix — связный текст. (Повторы «помочьь» — побочный эффект greedy decoding с repetition penalty.)

2.6. mistral-7B Russian (regression check)

> *«Привет! Космос - это область, состоящая из космического пространства и всех небесных тел, включая планеты, луны, звезды и галакти»*

arch=`llama` → `rope=norm`. Регрессии НЕТ.

2.7. qwen3-0.6B Russian — capacity issue

```
<think>
!!!
```

- cpu_fused_rmsnorm_qkv_gemv для не-Q4_K делает 3 separate `cpu_quant_gemv` calls — каждый на свой slice.

Тем не менее GEMV выдаёт логиты, у которых argmax = 0 = `<unk>`. Что-то ещё не так. Кандидаты: (a) Q5_K block layout у phi3 имеет другую permutation внутри блока, (b) phi3 LongRoPE с `rope_factors` per-frequency не реализован, (c) phi3 RMSNorm имеет иную convention. Out of scope сессии — требует side-by-side дамп активаций между нашим кодом и llama.cpp.

3. Скорость: 11.4 baseline и почему 8.0

Конфигурация	tok/s	Russian quality
per-tensor scale + interleaved RoPE + spec K=1	11.4	broken для qwen3
per-tensor scale + NEOX RoPE + spec K=1	~10.5 (estimate)	работает
per-block scale + NEOX RoPE + spec K=1	8.0	работает

Юзер выбрал **quality > speed**. Per-block scale (точнее квантизация активаций) даёт правильные скоры внимания на массивных активациях qwen3, но добавляет **~7%** overhead per замеру. NEOX RoPE сам по себе без overhead — те же O(head_dim/2) операций, просто другая индексация пар.

4. Что незакрыто и план

4.1. gemma3 per-layer alternating RoPE + SWA

Нужно: расширить `ModelConfig` до per-layer rope config (массив длины `num_layers`), детектить gemma3 SWA pattern (каждые 5 из 6 слоёв — local), применять разные `freq_base / scale / sliding_window` per слой.

Объём: ~150 LoC в `gguf_model.h` + ~50 LoC dispatch в forward path.

4.2. phi3.5 — verify после rebuild4

Loader split реализован. Pending: дождаться rebuild и протестировать. Возможно потребуется ещё один маленький fix (chat template, EOS токен, pre-attn residual).

4.3. Per-layer rope для qwen3-VL / qwen3.5

llama.cpp добавил `LLM_ARCH_QWEN35 → LLAMA_ROPE_TYPE_IMROPE` и `QWEN3VL → LLAMA_ROPE_TYPE_MROPE`. Эти варианты потребуют свои функции `rope_apply_fused_mrope` / `imrope`. Вне scope этой сессии.

5. Воспроизведение

```
plink -P 8199 -i ELBRUS_KEY paperclipdnb@w205p.mcst.ru
cd /home/paperclipdnb/promethorch
git pull origin main  # commits b144db2..2b317c4
cmake --build build_elbrus --target test_gguf_inference -j 4

# qwen3-4B Russian, single-process
PT_Q8_SOA=1 PT_PER_BLOCK_SCALE=1 PT_LM_HEAD_FP=1 PT_NO_FFN_SOA=1 \
PT_NO_NUMA_POOL=1 OMP_NUM_THREADS=32 PT_NO_THINK=1 \
  ./build_elbrus/examples/gguf/test_gguf_inference \
    /home/paperclipdnb/gguf_models/qwen3-4b-Q4_K_M.gguf \
    --max-tokens 60 --greedy --chat \
    "Привет! Расскажи про космос на русском."

# qwen3-4B Russian, TP-4
for r in 0 1 2 3; do
  PT_Q8_SOA=1 PT_PER_BLOCK_SCALE=1 PT_LM_HEAD_FP=1 PT_NO_FFN_SOA=1 \
  PT_NO_NUMA_POOL=1 OMP_NUM_THREADS=8 OMP_PLACES=cores OMP_PROC_BIND=close \
  PT_DDP_SHM=1 PT_NO_THINK=1 \
  numactl --cpunodebind=$r --membind=$r \
    ./build_elbrus/examples/gguf/test_gguf_inference \
      /home/paperclipdnb/gguf_models/qwen3-4b-Q4_K_M.gguf \
      --nprocs 4 --rank $r --master-addr 127.0.0.1 --master-port 29610 \
      --max-tokens 60 --greedy --chat \
      "Привет!" &
done
wait
```

6. Git

```
commits на github (origin/main):
  2b317c4  fix(gemma3): пропускаем rope_scale=8.0 — нужен per-layer alternating
  445dee4  fix(rope+phi3+gemma3): RoPE linear scaling + Phi-3 merged QKV/gate-up split
  550b8e9  test(rope-neox): TP-4 verification scripts + baseline conditions check
  ee80229  test(rope-neox): scripts для verify qwen/qwen2/qwen3/gemma3/phi3 + TP-4 bench
  b144db2  fix(rope): NeoX-style RoPE для qwen/qwen2/qwen3/gemma/gemma3/phi3 семейств
  …
```

Memory: `~/.claude/projects/.../memory/project_qwen3_rope_neox_root_cause.md`