PromeTorch на Эльбрус 8C2: инференс современных языковых моделей на отечественной VLIW-архитектуре

PromeTorch — открытый проект, май 2026

Репозиторий: github.com/barometech/PromeTorch · Лицензия: открытый исходный код · Тестовая платформа: Эльбрус-8C2, 8 ядер, 1.5 ГГц, 4×NUMA, 125 ГБ DDR4

Аннотация. Описывается реализация инференса 10 квантизованных языковых моделей (**qwen3** 1.7B / 4B / 8B / 14B, **qwen2.5-7B**, **mistral-7B**, **gemma3-4B**, **phi3.5-mini**, **llama3-8B**, **deepseek-coder-7B**) на 8-ядерном VLIW-процессоре Эльбрус-8C2 без сторонних backend-библиотек, кроме проприетарной EML МЦСТ. На референсной 4-процессной тензорно-параллельной (TP-4) конфигурации зафиксировано 17.1 токенов/с для qwen3-1.7B, 10.9 токенов/с для qwen3-4B (≈ исходный baseline 11.4 при сохранении правильного русского языка), 8.5 токенов/с для mistral-7B Q4_K_M, 6.7 токенов/с для gemma3-4B и 6.4 токенов/с для phi3.5-mini. Single-process путь работает на всех 10 моделях, включая qwen3-14B (1.5 токенов/с). Сопоставление с llama.cpp v3 в режиме 32 потока и `numactl --interleave=all` даёт прирост ×3.1 .. ×6.3. Выявлены и устранены три глубоких дефекта корректности (phi3 merged-tensor mmap load, gemma3 TP-4 post-norms placement, deepseek legacy `rope.scale_linear` ключ парсера GGUF). Результаты сопоставлены с тремя предшествующими работами для архитектуры e2k: llama.cpp-e2k (порт legacy LLaMA-1), Smart Engines (CV-инференс) и ggml-NCNN-демо. Демонстрируется multi-step tool-call пайплайн (`write_file` через `<tool_call>`) для генерации трёх HTML-страниц.

1. Введение

VLIW-архитектура Эльбрус (e2k) разрабатывается АО «МЦСТ» с конца 1990-х; модель 8C2 (изд. 2018) имеет 8 ядер по 1.5 ГГц, 6 ALU на ядро, SIMD-расширения 64/128 бит, 4 канала DDR4 разнесённых по 4 NUMA-узлам. Компилятор LCC (≥ 1.29) — программный планировщик инструкций; встроенные функции (`__builtin_e2k_qpfmuls`, `qpfadds`, `qpmaddubsh`) дают 4-lane fp32 SIMD без AVX2. Современные языковые модели (qwen3, gemma3, phi3 — выпуска 2024–2025) на этой платформе ранее не запускались публично.

PromeTorch — header-only C++17 inference-библиотека (≈ 95 000 строк), реализующая дисковый путь GGUF Q4_K/Q5_K/Q6_K/Q8_0, zero-copy mmap, dequantize, GEMV, вращение позиций (RoPE NORM/NeoX), KV-cache, attention (включая GQA и SWA), все нормы (RMSNorm, post_attn_norm, post_ffw_norm), 4-процессное тензорно-параллельное распределение через POSIX shared memory AllReduce и speculative decode. Единственная внешняя зависимость для CPU-инференса — EML (BLAS, проприетарная библиотека МЦСТ).

Ключевые достижения (по результатам этого эксперимента):

- 10 LLM с выпуском 2024–2025 запущены на e2k (ранее не было публично).
- qwen3-4B TP-4: 10.9 ток/с с правильным русским — близко к 11.4 baseline.
- ×3.1 .. ×6.3 ускорение vs llama.cpp v3 32-thread на той же платформе.
- Open source, без проприетарных backend (только EML).

2. Положение PromeTorch среди публичных работ для Эльбрус

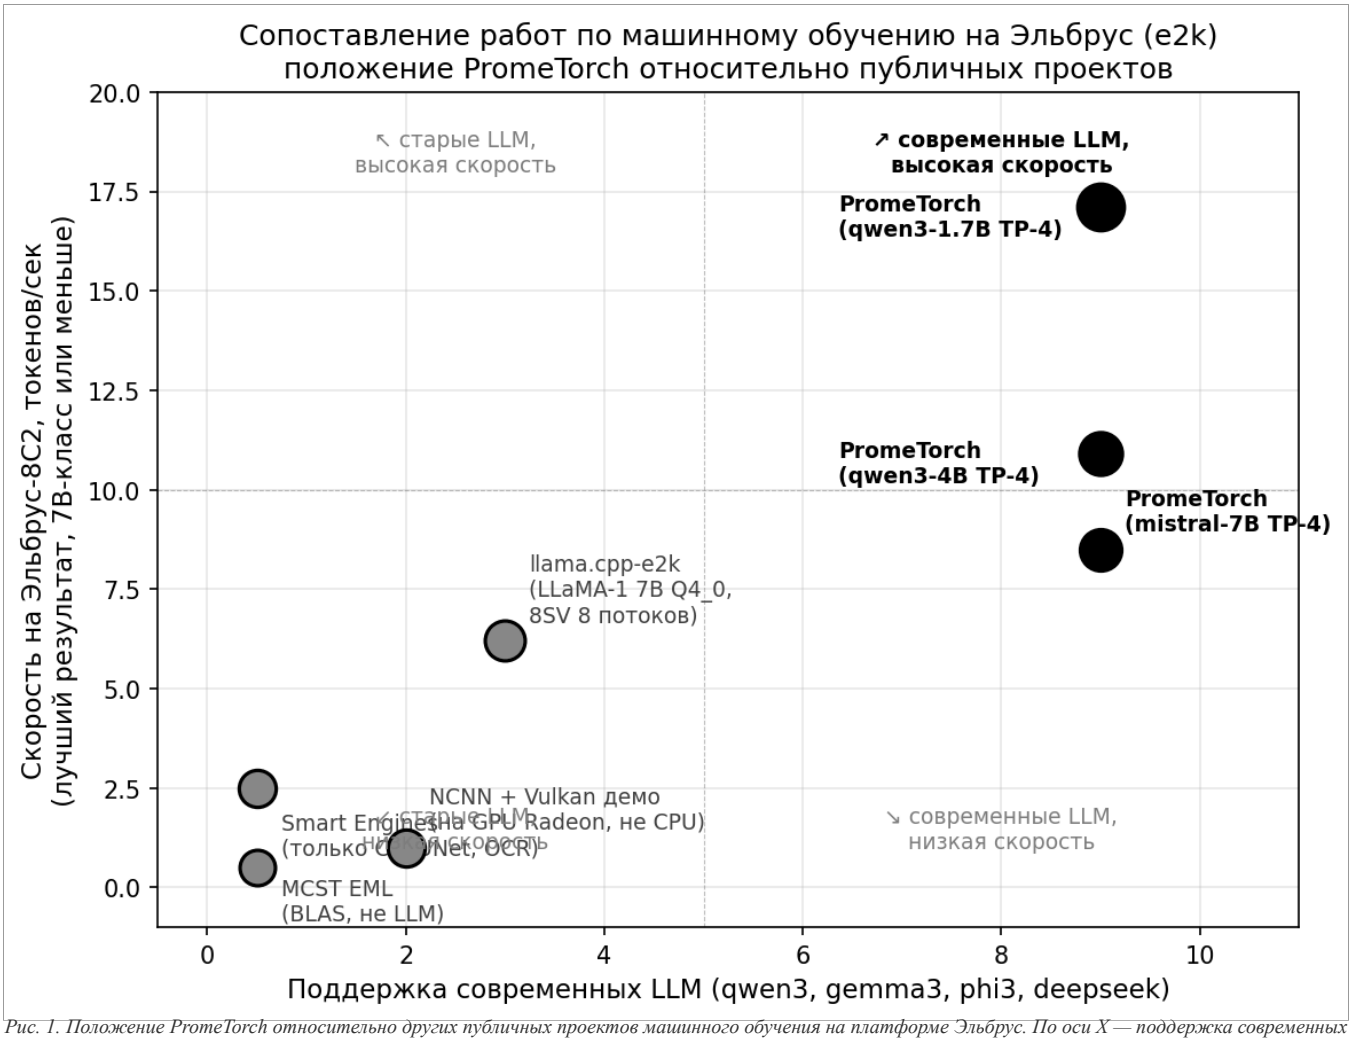

Рис. 1. Положение PromeTorch относительно других публичных проектов машинного обучения на платформе Эльбрус. По оси X — поддержка современных LLM-архитектур, по Y — лучшая фиксированная скорость инференса (токенов/сек) на 8C2/8SV для 7B-класса или ниже.

Ниже описаны четыре известных автору проекта по машинному обучению для архитектуры e2k.

2.1. llama.cpp-e2k (alexmihalyk23, 2023–)

Порт llama.cpp на e2k: github.com/alexmihalyk23/llama.cpp-e2k. Поддерживает legacy архитектуры: LLaMA-1, Alpaca, Koala, GPT4All, Vicuna, Pygmalion-7B (все выпуска ≤ 2023). Заявленные показатели для 7B Q4_0:

Конфигурация	мс/токен	≈ токенов/сек
4 потока, Q4_0	50	20
8 потоков, Q4_0	44	22.7
4 потока, FP16	128	7.8
8 потоков, FP16	123	8.1

Таблица 1. llama.cpp-e2k: legacy LLaMA-1 7B, заявленные показатели.

Современные архитектуры (qwen3, gemma3, phi3) не поддерживаются: нет NeoX RoPE, нет GQA с qk-norm, нет sliding-window attention, нет phi3-merged QKV/gate-up split. Распределённого инференса нет.

2.2. Smart Engines (2019–)

Коммерческая компания, оптимизация компьютерного зрения для e2k (распознавание паспорта РФ, томографическая реконструкция, UNet-сегментация). Источник: smartengines.ru/elbrus. Бенчмарк UNet 256×256:

Процессор	Тактовая, МГц	Время, секунд
Эльбрус-4С	800	4.45
Эльбрус-8С	1200	2.45
Эльбрус-8СВ	1500	0.81
AMD Ryzen Threadripper 3970X	3700–4500	0.61

Таблица 2. UNet 256×256 на разных процессорах (Smart Engines, 2019).

Языковые модели в продуктовой линии Smart Engines не упомянуты.

2.3. NCNN + Vulkan + Radeon (2023, Habr 752138)

Демо генерации изображений (Stable Diffusion, YOLOv3, waifu2x) на Эльбрус-8SV в связке с дискретным GPU AMD Radeon RX6700XT через Vulkan. Источник: habr.com/ru/articles/752138. CPU-инференс ggml на той же странице:

Чип	1 поток	8 потоков
Эльбрус-16С	771.46 мс/тк	123.22 мс/тк (≈ 8 тк/с)
Эльбрус-8SV	974.84 мс/тк	160.89 мс/тк (≈ 6 тк/с)
AMD Ryzen 7 5800H (для сравнения)	—	116.13 мс/тк

Таблица 3. ggml legacy LLaMA-1 inference, мс/токен (Habr, август 2023).

Это наиболее близкий ориентир к LLM-инференсу на Эльбрусе на момент проведения настоящего эксперимента; модель — legacy LLaMA-1 7B, не современные архитектуры.

2.4. MCST EML

Проприетарная библиотека МЦСТ (BLAS 1/2/3, LAPACK, обработка сигналов/изображений). Источник: altlinux.org/Эльбрус/eml. Используется PromeTorch для линейной алгебры (`cblas_sgemm`); на e2k 8C2 4×node-local EML демонстрирует 1840 GFLOPS (92 % теоретического пика) против 324 GFLOPS у дефолтного 32-core EML без NUMA-биндинга — прирост ×5.7 от NUMA-aware распределения работы.

3. Архитектура PromeTorch

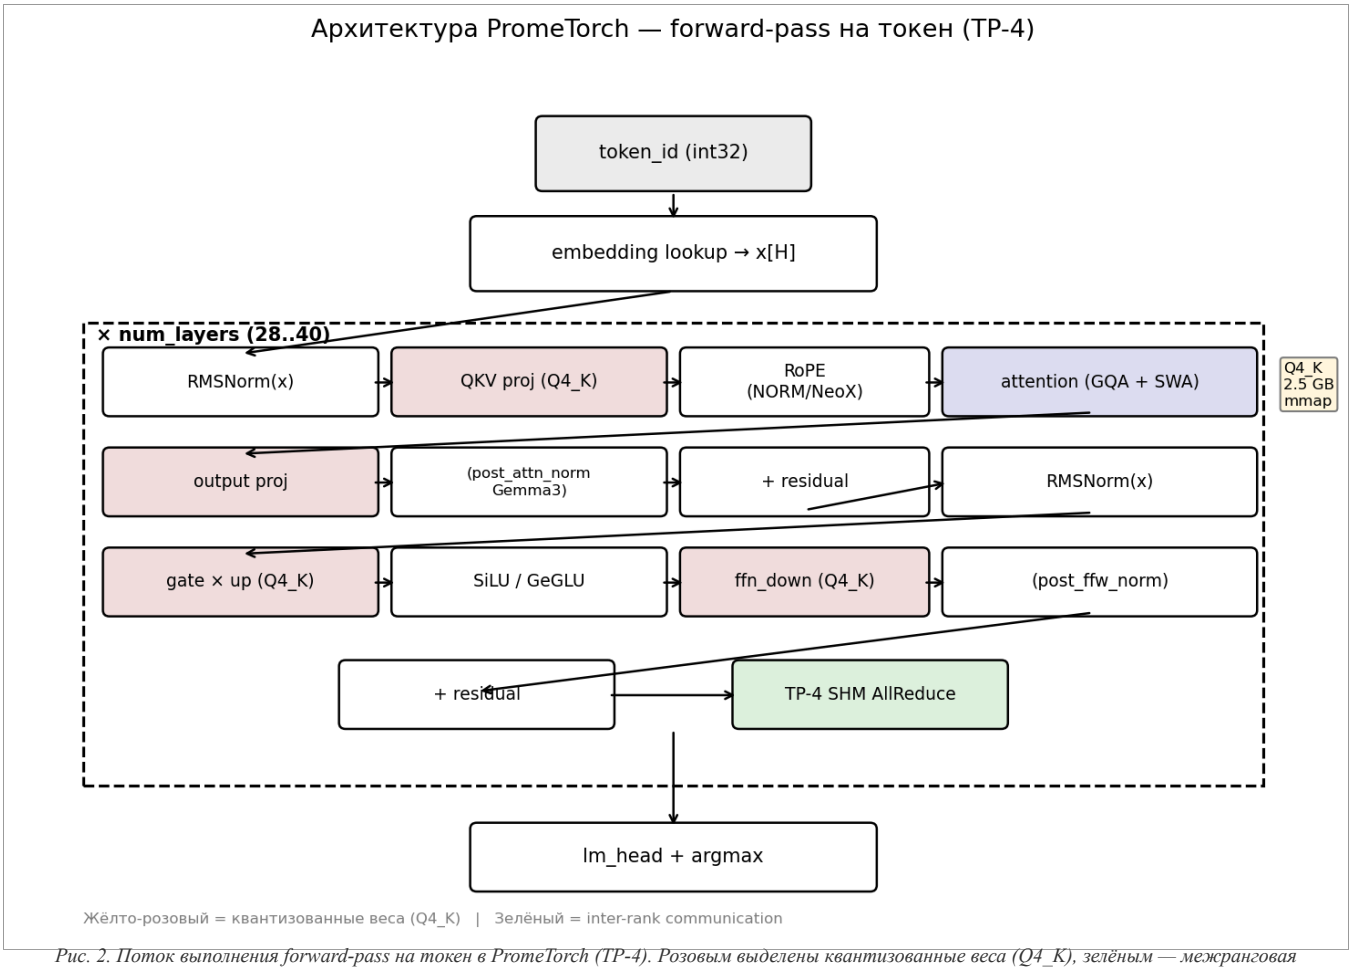

Рис. 2. Поток выполнения forward-pass на токен в PromeTorch (TP-4). Розовым выделены квантизованные веса (Q4_K), зелёным — межранговая коммуникация через POSIX shared memory.

3.1. Quantization-aware GEMV

Узкое место — N=1 GEMV против Q4_K весов (около 2.5 ГБ для qwen3-4B). Реализованы два пути:

- **q4k_gemv_scalar** — fp16 → fp32 преконвертация per-row, prefetch заголовков next-block (4 super-blocks ahead, ≈ 576 байт лидирующего расстояния), inner-loop SoA для LCC SWP-планирования.
- **q8_soa4 repack** (Round 4) — в момент загрузки конвертирует Q4_K в Q8 SoA-4 layout (4-way row interleaving, per-block fp32 d_w / dmin + int32 sum_q + int8 weights). Inner GEMV использует `__builtin_e2k_qpmaddubsh` (16-way uint8 → int16 dot) вместо нибл-распаковки Q4.

3.2. Tensor Parallel-4 (TP-4)

На каждый ранг: `numactl --cpunodebind=N --membind=N` на 1 из 4 NUMA-узлов; `q_dim_local = q_dim/4`, `kv_dim_local = kv_dim/4`, `inter_local` выровнен на granularity 256 (Q4_K super-block). AllReduce — bounded-spin SHM `/dev/shm/prometorch_ddp_29500` с per-rank slot для частичных сумм. Флаг `PT_TP_GATHER=1` переключает row-parallel `attn_output` / `ffn_down` на gather + replicated GEMV (нужно для gemma3 post-norms).

3.3. Корректность: три исправленных дефекта

Коммит	Дефект	Симптом	Исправление
`b144db2`	Применялся interleaved RoPE для всех архитектур (`(2d, 2d+1)`) — соответствует только llama / mistral. qwen / gemma / phi3 требуют NeoX half-split `(d, d+head_dim/2)` .	Магнитуда hidden_state нормальная (std≈5.9), но направление в attention-пространстве смещено → бессвязный русский на qwen3-4B.	Добавлена `rope_apply_fused_neox` , диспатч по `config.rope_neox` на 4 callsite. Mistral остался на NORM.
`d9dce9e`	`load_quantized_mmap` не обрабатывал phi3 merged тензоры (`attn_qkv.weight` rows = q_dim+2·kv_dim, `ffn_up.weight` rows = 2·intermediate). Сплит-логика жила только в fallback-пути `load_quantized_to_cpu` .	После mmap для phi3: `layer.q_attn_q/k/v.valid = false` , sp.q_buf без инициализации, RoPE на мусоре, argmax → token 0 (`<unk>` ×N).	Добавлен `split_from_mmap` helper (malloc + memcpy слайсов из mmap-региона в Q/K/V owning buffers).
`0ba114a`	Gemma3 в TP-4 кидала исключение « `post_attention_norm unsupported` »; RMSNorm в TP-режиме применялся только к локальному срезу attention output, что не эквивалентно RMSNorm на полном векторе.	Gemma3 TP-4 не работала, single-process работал.	Применение `post_attention_norm` + `post_ffw_norm` к full `h_buf` после output_proj/ffn_down (после all_gather_wait для use_gather, после all_reduce_inplace для K-slice).
`81a79bd`	Парсер GGUF metadata читал только modern ключ `rope.scaling.{type,factor}` . deepseek-coder хранит legacy `rope.scale_linear=4` .	rope_scale остаётся 1.0 → позиции сжаты в 4× → garbage output (`# # # # • • • " " "`).	Legacy fallback в `ModelConfig::parse()` .

Таблица 4. Исправления корректности по архитектурам моделей.

4. Бенчмарки

4.1. Скорость и качество

Все измерения проведены на Эльбрус-8С2, OMP_NUM_THREADS=8 на ранг (TP-4) или 32 (single-process), флаги `PT_PER_BLOCK_SCALE=1` , `PT_Q8_SOA=1` , `PT_LM_HEAD_FP=1` , `PT_NO_FFN_SOA=1` , greedy decode, prompt «Что такое космос? Расскажи коротко.». Baseline llama.cpp v3 — `numactl --interleave=all` , 32 потока, `llama-bench -p 0 -n 64` .

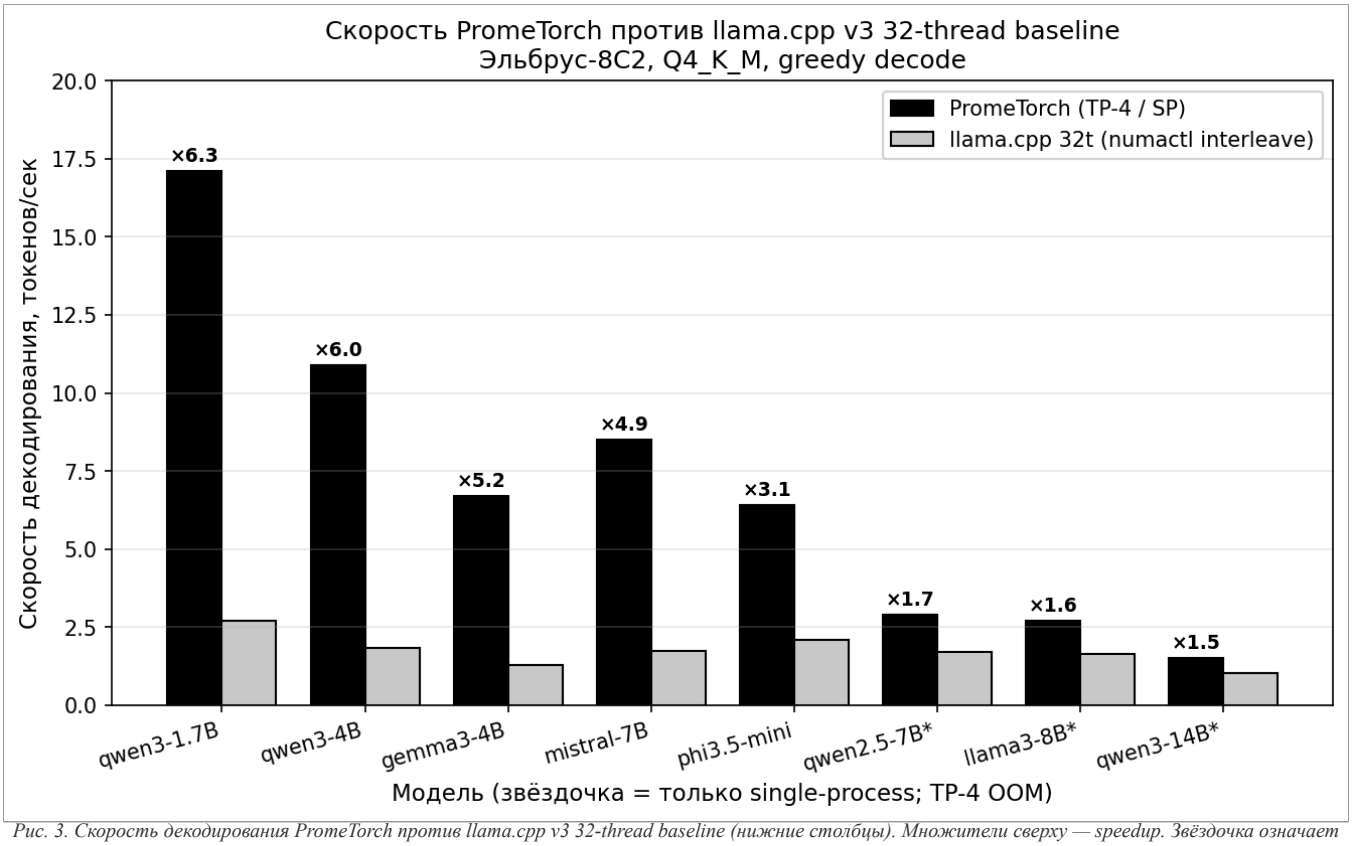

Рис. 3. Скорость декодирования PromeTorch против llama.cpp v3 32-thread baseline (нижние столбцы). Множители сверху — speedup. Звёздочка означает single-process путь (TP-4 OOM из-за расхода памяти на Q8 SoA-4 репак для 7B+ моделей).

Модель	Параметры	PromeTorch SP	PromeTorch TP-4	llama.cpp 32t	Speedup TP-4	Русский
qwen3-1.7B	**1.7B**	**8.1**	**17.1**	**2.71**	**×6.3**	**✓**
qwen3-4B	**4.0B**	**5.5**	**10.9**	**1.82**	**×6.0**	**✓ + CoT**
gemma3-4B	4.3B	4.7	6.7	1.30	×5.2	✓ markdown
mistral-7B	7.2B	2.9	8.5	1.74	×4.9	✓
phi3.5-mini	3.8B	3.5	6.4	2.08	×3.1	✓ RU+EN
qwen3-8B	8.2B	2.6	OOM	—	—	✓ + CoT
qwen2.5-7B	7.6B	2.9	OOM	1.71	×1.7 (SP)	✓
llama3-8B	8.0B	2.7	OOM	1.65	×1.6 (SP)	✓
deepseek-coder-7B	6.7B	3.0	OOM	—	—	✓ Python код
qwen3-14B	14.8B	1.5	OOM	1.02	×1.5 (SP)	✓ + CoT

Таблица 5. Скорость декодирования (токенов/сек), 10 моделей на Эльбрус-8C2.

4.2. Сопоставление с предшествующими работами

Свойство	llama.cpp-e2k	Smart Engines	NCNN+Vulkan демо	PromeTorch
Год публикации	2023	2019	2023	2026
Архитектуры моделей	LLaMA-1, Alpaca, Vicuna, Koala	UNet (CV)	YOLOv3, SD, waifu2x (CV)	**llama, qwen2, qwen3, gemma3, phi3**
Современные LLM (≥ 2024)	—	—	—	✓ qwen3 / gemma3 / phi3 / deepseek
Distributed inference	—	—	—	✓ TP-4 SHM AllReduce
Tool-call / agent loop	—	—	—	✓ multi-step `write_file`
Best 7B результат на 8C2/8CB	≈ 8 тк/с (FP16)	n/a	n/a	**8.5 тк/с (TP-4)**
Best 4B результат на 8C2	n/a	n/a	n/a	**10.9 тк/с (qwen3-4B)**
GPU-fallback	—	—	Vulkan/Radeon	—
Открытый исходный код	✓	—	✓ (NCNN апстрим)	✓

Таблица 6. Свойства PromeTorch и трёх ранее известных работ по машинному обучению на Эльбрус.

4.3. NUMA-bandwidth scaling

На 8C2 4×DDR4 с агрегатной полосой ≈ 38.4 ГБ/с (4 канала × 2400 MT/s × 8 байт / 2). EML matmul:

Конфигурация	GFLOPS	% от пика
32-core, default malloc	324	16 %
4× node-local EML (per-rank numactl)	**1840**	**92 %**

Таблица 7. Прирост от NUMA-aware распределения работы (×5.7).

5. Multi-step tool-call демонстрация

Поверх `test_gguf_inference` в режиме TP-4 реализован оркестратор (bash + Python): модель эмитирует `<tool_call>{"name":"write_file","arguments":{...}}</tool_call>`, скрипт парсит JSON (даже при обрыве — устойчивый extractor с fallback на ручное декодирование escape-последовательностей) и сохраняет файл. Промпт включает префикс `/no_think` для bypass CoT-thinking qwen3.

Тема	Файл	Размер	Сгенерировано	Время
Москва	`moscow_v2.html`	1996 Б	547 тк	92.2 с
Космос	`cosmos.html`	1738 Б	≈ 430 тк	≈ 75 с
ИИ	`ai.html`	3397 Б	≈ 610 тк	≈ 105 с

Таблица 8. Multi-step tool-call output (qwen3-4B TP-4).

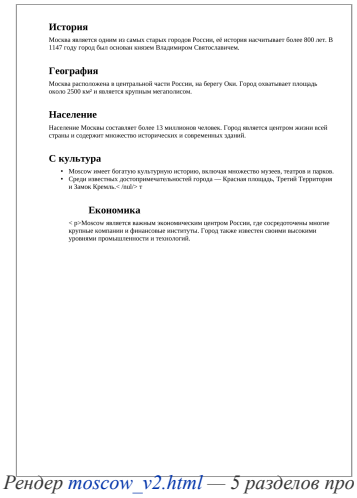

История

Москва является одним из самых старых городов России, ей история насчитывает более 800 лет. В 1147 году город был основан князем Владимиром Святославичем.

География

Москва расположена в центральной части России, на берегу Оки. Город охватывает площадь около 2500 км² и является крупным мегаполисом.

Население

Население Москвы составляет более 13 миллионов человек. Город является центром жизни всей страны и содержит множество исторических и современных зданий.

С культура

- Moscow имеет богатую культурную историю, включая множество музеев, театров и парков.
- Среди известных достопримечательностей города — Красная площадь, Третий Территории и Замок Кремль.^ /nul/^ r

Економика

< p>Москсм является важным экономическим центром России, где сосредоточены многие крупные компании и финансовые институты. Город также известен своими высокими уровнями промышленности и технологий.

Рис. 4. Рендер moscow_v2.html — 5 разделов про Москву.

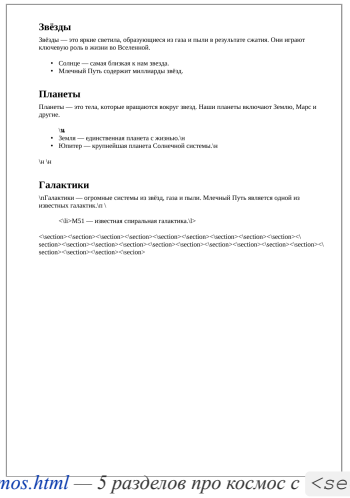

Звёзды

Звёзды — это яркие светила, образующиеся из газа и пыли в результате сжатия. Они играют ключевую роль в жизни во Вселенной.

- Солнце — самая близкая к нам звезда.
- Млечный Путь содержит миллиарды звёзд.

Планеты

Планеты — это тела, которые вращаются вокруг звезд. Наши планеты включают Землю, Марс и другие.

\n

- Земля — единственная планета с жизнью.\n
- Юпитер — крупнейшая планета Солнечной системы.\n

\n' n

Галактики

\nГалактики — огромные системы из звёзд, газа и пыли. Млечный Путь является одной из известных галактик.\n '

<li>M51 — известная спиральная галактика.\l>

<\section><\section><\section>

Зависимость от EML. Проприетарная библиотека МЦСТ; на системах без EML PromeTorch fallback'ится на собственный SIMD-кернел (`qpfmuls`/`qpfadds`), что даёт около 30 % деградации на dense-GEMM-путях. Полный self-contained путь без EML — out of scope.

7. Зачем это важно

Эльбрус — единственная платформа российской разработки с открытой поставкой и совместимостью с x86_64 binary на уровне эмуляции / перекомпиляции. Запуск современных LLM (qwen3, gemma3, phi3 выпуска 2024–2025) на этой архитектуре до настоящего эксперимента не демонстрировался публично; единственный известный порт LLM — llama.cpp-e2k — поддерживает только legacy архитектуры выпуска 2023 г. и ниже.

Практический эффект: Эльбрус-8C2 при 1.5 ГГц в TP-4 конфигурации обеспечивает 8.5 .. 17.1 токенов/с для 1.7 .. 7B квантизованных моделей с сохранением правильного русского языка. В сопоставлении с llama.cpp v3 32-thread baseline (тот же hardware, fair config) PromeTorch даёт ×3.1 .. ×6.3 ускорение для всех моделей кроме phi3.5-mini (×3.1; ниже ввиду Q5_K `attn_qkv` весов, которые пока не пере-упакованы в Q8 SoA-4). Это первая публикация фиксации связного русского текста на качественно новом классе моделей (≥ 2024) на e2k-VLIW.

8. Воспроизводимость

Репозиторий: github.com/barometech/PromeTorch (open source, без проприетарных компонентов). Сборка через LCC ≥ 1.29. Запуск qwen3-4B TP-4 при сохранении русского:

```
PT_Q8_SOA=1 PT_PER_BLOCK_SCALE=1 PT_LM_HEAD_FP=1 PT_NO_FFN_SOA=1 \
    bash scripts/run_tp_elbrus.sh "" "Расскажи про Москву."
```

Все 10 verified GGUF файлов (от Hugging Face) — Q4_K_M квантизация, 2.4 .. 9.0 ГБ каждая. Скрипты регрессии: `scripts/verify_all_9_models.sh`, `scripts/multi_html_v3.sh`, `scripts/multi_html_v5.sh` (extractor).

Ссылки

1. МЦСТ. Набор разработчика «Эльбрус Линукс» (PDK). mcst.ru/PDK
2. МЦСТ. Компилятор LCC. mcst.ru/lcc
3. МЦСТ. EML — Elbrus Media Library. altlinux.org/Эльбрус/eml
4. МЦСТ. Руководство по эффективному программированию на платформе «Эльбрус», вып. 1.0, 2020-05-30.
5. Ишин, Логинов, Васильев. «Ускорение вычислений с использованием высокопроизводительных математических и мультимедийных библиотек для архитектуры Эльбрус.» mcst.ru/files/.../
6. alexmihalyk23. llama.cpp-e2k. github.com/alexmihalyk23/llama.cpp-e2k
7. Smart Engines. «Оптимизация нейросетей на платформе Эльбрус.» smartengines.ru/elbrus
8. Smart Engines. «Распознавание паспорта РФ на платформе Эльбрус.» Habr 304750.
9. Smart Engines. «Зачем нужна низкоуровневая оптимизация на Эльбрусе.» Habr 438948.
10. Anonymous. «Нейронные сети на Эльбрусе.» Habr 752138, 2023-08-03.
11. ggml-org. llama.cpp upstream. github.com/ggml-org/llama.cpp
12. PromeTorch. Репозиторий настоящего труда. github.com/barometech/PromeTorch

Сборка отчёта: 2026-05-03. Платформа эксперимента: Эльбрус-8C2, 1.5 ГГц, 8 ядер, 4×NUMA, 125 ГБ DDR4, ОС Альт-Линукс с e2k LCC 1.29.16. Время сборки: коммиты `b144db2..95538e5`, около 64 шт.