

PromeTorch на Эльбрус 8C2: инференс современных языковых моделей на отечественной VLIW-архитектуре

PromeTorch

Репозиторий: github.com/barometech/PromeTorch · Лицензия: открытый исходный код · Тестовая платформа: Эльбрус-8C2, 8 ядер, 1.5 ГГц, 4×NUMA, 125 ГБ DDR4

Аннотация.

qwen2.5-7B mistral-7B gemma3-4B phi3.5-mini llama3-8B deepseek-coder-7B

qwen3

1. Введение

PromeTorch

Ключевые достижения (по результатам этого эксперимента):

-
-
-
-

2. Положение PromeTorch среди публичных работ для Эльбрус




Рис. 1. Положение PromeTorch относительно других публичных проектов машинного обучения на платформе Эльбрус. По оси X — поддержка современных LLM-архитектур, по Y — лучшая фиксированная скорость инференса (токенов/сек) на 8C2/8SV для 7B-класса или ниже.

2.1. llama.cpp-e2k (alexmhalyk23, 2023—)

≤

Конфигурация	мс/токен	≈ токенов/сек

Таблица 1. llama.cpp-e2k: legacy LLaMA-1 7B, заявленные показатели.

2.2. Smart Engines (2019—)

Процессор	Тактовая, МГц	Время, секунд

Таблица 2. UNet 256×256 на разных процессорах (Smart Engines, 2019).

2.3. NCNN + Vulkan + Radeon (2023, Habr 752138)

Чип	1 поток	8 потоков

Таблица 3. ggml legacy LLaMA-1 inference, мс/токен (Habr, август 2023).

2.4. MCST EML

3. A

--

3.1.


3.3. Корректность: три исправленных дефекта

Коммит	Дефект	Симптом	Исправление

Таблица 4. Исправления корректности по архитектурам моделей.

4. Бенчмарки

4.1. Скорость и качество






Рис. 3. Скорость декодирования PromeTorch против llama.cpp v3 32-thread baseline (нижние столбцы). Множители сверху — speedup. Звёздочка означает single-process путь (TP-4 OOM из-за расхода памяти на Q8 SoA-4 репак для 7B+ моделей).

Модель	Параметры	PromeTorch SP	PromeTorch TP-4	llama.cpp 32t	Speedup TP-4	Русский
qwen3-1.7B	1.7B	8.1	17.1	2.71	×6.3	✓
qwen3-4B	4.0B	5.5	10.9	1.82	×6.0	✓ + CoT
						✓
						✓
						✓
				✎	✎	✓
						✓
						✓
				✎	✎	✓
						✓

Таблица 5. Скорость декодирования (токенов/сек), 10 моделей на Эльбрус-8C2.




Рис. 4. Рендер `moscow_v2.html` — 5 разделов про Москву.




Рис. 5. Рендер `cosmos.html` — 5 разделов про космос с `<section>`-тегами.




Рис. 6. Рендер `ai.html` — страница про искусственный интеллект, 5 разделов.

6. Ограничения

OOM в TP-4 для 7B+ моделей.

qwen3-0.6B.

Зависимость от EML.



7. Зачем важно

8. Воспроизводимость



Ссылки

